



INSTITUTO FEDERAL

Paraíba

Campus Campina Grande

**INSTITUTO FEDERAL DE CIÊNCIA E TECNOLOGIA DA PARAÍBA - CAMPUS
CAMPINA GRANDE
ENGENHARIA DE COMPUTAÇÃO**

ICARO M. DE ALCANTARA BEZERRA

JOÃO M. AMORIM DE ALMEIDA

SISTEMA DE DETECÇÃO DE FALHAS EM MÁQUINAS INDUSTRIAIS

CAMPINA GRANDE

2025

ICARO MENDES DE ALCANTARA BEZERRA
JOÃO MARCOS AMORIM DE ALMEIDA

SISTEMA DE DETECÇÃO DE FALHAS EM MÁQUINAS INDUSTRIAIS

Relatório apresentado à disciplina Técnicas de Prototipagem, do curso de Engenharia de Computação IFPB como requisito parcial para aprovação na disciplina, sob a orientação da prof.^a Dr. Moacy Pereira da Silva.

CAMPINA GRANDE

2025

RESUMO

Este trabalho apresenta o desenvolvimento de um sistema embarcado para detecção de falhas em máquinas industriais, utilizando aprendizado de máquina aplicado a um microcontrolador STM32F103CBT6. O sistema captura dados de vibração por meio de um sensor MPU6050 e os analisa utilizando um modelo gerado pelo NanoEdge AI Studio. O objetivo é identificar padrões normais e anômalos no funcionamento dos motores, possibilitando a manutenção preditiva. Para validar a proposta, foram conduzidos testes utilizando dois coolers de CPU, um em funcionamento normal e outro com falha simulada. Os resultados demonstram que o modelo treinado foi capaz de identificar anomalias com alta precisão, apresentando uma taxa de acerto de 100%.

Palavras-chave: detecção de falhas; aprendizado de máquina; NanoEdge AI; STM32.

LISTA DE TABELAS

Tabela 1: Análise dos resultados

LISTA DE ABREVIATURAS E SIGLAS

IA – Inteligência Artificial

I2C – Inter-Integrated Circuit

MPU6050 – Unidade de Medida Inercial MPU6050

STM32 – Microcontrolador STM32

UART – Universal Asynchronous Receiver-Transmitter

SUMÁRIO

- 1. INTRODUÇÃO**
 - 1.1. Tema**
 - 1.2. Problematização e justificativa**
 - 1.3. Objetivos**
- 2. METODOLOGIA**
 - 2.1. Configuração do hardware**
 - 2.2. Coleta e processamento de dados**
 - 2.3. Treinamento do modelo de IA**
 - 2.4. Implementação no STM32**
- 3. RESULTADOS E DISCUSSÃO**
 - 3.1. Resultados obtidos**
 - 3.2. Análises e considerações**
- 4. CONSIDERAÇÕES FINAIS**
- 5. REFERÊNCIAS**

1 INTRODUÇÃO

A detecção precoce de falhas em máquinas industriais é essencial para a manutenção preditiva, reduzindo custos operacionais e aumentando a eficiência dos equipamentos. Este projeto propõe o desenvolvimento de um sistema embarcado que utiliza aprendizado de máquina para identificar padrões anômalos em motores. A abordagem adotada baseia-se na captura de dados de vibração com um sensor MPU6050, que transmite as informações para um microcontrolador STM32F103CBT6. Esses dados são analisados por um modelo de inteligência artificial gerado pelo NanoEdge AI Studio. Os testes foram conduzidos em dois coolers de CPU: um sem alterações e outro com falha simulada por meio da adição de pesos às pás do rotor.

1.1. Tema

O estudo trata da aplicação de aprendizado de máquina embarcado para detecção de falhas mecânicas em motores industriais.

1.2. Problematização e Justificativa

A necessidade de prever falhas mecânicas antes que causem danos irreversíveis é um desafio na indústria. Métodos convencionais de monitoramento são custosos e exigem grande infraestrutura. Este projeto visa demonstrar que um sistema embarcado pode ser uma solução eficiente, acessível e de baixo custo para esse problema.

1.3. Objetivos

- **Objetivo Geral:** Desenvolver um sistema de detecção de falhas baseado em aprendizado de máquina, utilizando o STM32F103CBT6 e o sensor MPU6050.
- **Objetivos Específicos:**
 - Coletar e processar dados de vibração do motor utilizando o MPU6050.
 - Treinar um modelo de inteligência artificial com o NanoEdge AI Studio.
 - Integrar a biblioteca gerada ao firmware do STM32F103CBT6.
 - Validar a eficiência do sistema por meio de testes experimentais.

2. METODOLOGIA

2.1. Configuração do Hardware

- Os seguintes componentes foram utilizados no sistema:
 - STM32F103CBT6 – Microcontrolador ARM Cortex-M3 (72 MHz).
 - MPU6050 – Sensor de aceleração e giroscópio de 6 eixos.
 - Coolers de CPU – Motores utilizados para simulação de falhas.
 - LED Indicador (GPIOB, pino 2) – Indicação de anomalia no sistema.
 - Interface UART – Comunicação serial (115200 bps).

2.2. Coleta e Processamento dos Dados

Os dados foram coletados no seguinte formato:

linha 1 - x0 y0 z0 x1 y1 z1 ... x255 y255 z255

linha 2 - x0 y0 z0 x1 y1 z1 ... x255 y255 z255

...

linha N - x0 y0 z0 x1 y1 z1 ... x255 y255 z255

Foram coletadas 500 linhas de funcionamento normal e 500 linhas de funcionamento anômalo.

2.3. Treinamento do Modelo de IA

O NanoEdge AI Studio foi utilizado para treinar o modelo, utilizando um conjunto de 1000 amostras divididas igualmente entre normal e anômalo. O software realizou um benchmarking automático para selecionar a melhor abordagem para detecção de anomalias.

2.4. Implementação no STM32

Após o treinamento, a biblioteca de inferência foi incorporada ao firmware do STM32F103CBT6. A detecção de anomalias foi indicada por um LED e pelo envio de mensagens via UART.

3. RESULTADOS E DISCUSSÃO

3.1. Resultados Obtidos

Os testes demonstraram que o sistema foi capaz de detectar falhas com alta precisão.

Métrica	Esperado	Obtido
Precisão do modelo	95%	100%
Tempo de inferência	200ns	2s

Tabela 1: Análise dos resultados.

3.2. Análises e Considerações

O sistema apresentou uma taxa de acerto de 100% na detecção de anomalias, superando a expectativa inicial. Entretanto, o tempo de inferência foi superior ao esperado devido à latência na comunicação I2C e ao processamento no microcontrolador.

4. CONSIDERAÇÕES FINAIS

O projeto demonstrou que aprendizado de máquina embarcado pode ser uma solução eficaz para a detecção de falhas mecânicas em motores industriais. O uso do NanoEdge AI permitiu a implementação de um modelo de detecção robusto sem necessidade de servidores externos.

REFERÊNCIAS

YOUTUBE. PART I: STM32 HAL I2C and MPU6050 IMU. 2024. Disponível em: <https://www.youtube.com/watch?v=iJn70hPxT7E>. Acesso em: 10 mar. 2025.

YOUTUBE. PART II: STM32 HAL I2C and MPU6050 IMU. 2024. Disponível em: <https://www.youtube.com/watch?v=P7a6qxacnO4>. Acesso em: 10 mar. 2025.

YOUTUBE. Interface MPU6050/GY-521 with STM32 || LCD 20x4 || CubeMx || HAL || SW4STM. 2024. Disponível em: <https://www.youtube.com/watch?v=xxphp9wDnHA>. Acesso em: 10 mar. 2025.

YOUTUBE. Treinamento de modelos de IA no STM32. 2024. Disponível em: https://www.youtube.com/watch?v=yXMUv_C5FGk. Acesso em: 10 mar. 2025.
(Título não encontrado, é necessário acessar manualmente para verificar o nome correto.)

STMICROELECTRONICS. How to use NanoEdge AI Studio for anomaly detection. 2024. Disponível em: <https://community.st.com/t5/stm32-mcus/how-to-use-nanoedge-ai-studio-for-anomaly-detection/ta-p/697858>. Acesso em: 10 mar. 2025.

STMICROELECTRONICS. NanoEdge AI Library for anomaly detection (AD). 2024. Disponível em: [https://wiki.st.com/stm32mcu/wiki/AI:NanoEdge_AI_Library_for_anomaly_detection_\(AD\)](https://wiki.st.com/stm32mcu/wiki/AI:NanoEdge_AI_Library_for_anomaly_detection_(AD)). Acesso em: 10 mar. 2025.

STMICROELECTRONICS. STM32F103CB Microcontroller. 2024. Disponível em: <https://www.st.com/en/microcontrollers-microprocessors/stm32f103cb.html>. Acesso em: 10 mar. 2025.

TDK INVENSENSE. MPU-6000 Datasheet. 2015. Disponível em: <https://invensense.tdk.com/wp-content/uploads/2015/02/MPU-6000-Datasheet1.pdf>. Acesso em: 10 mar. 2025.

Página do ChatGPT:
OPENAI. ChatGPT. 2025. Disponível em: <https://chatgpt.com>. Acesso em: 10 mar. 2025.